

Reporte tecnico: entrenamiento, ajuste y registro de modelos

Proyecto: Actividad 5

Dataset: Breast Cancer Wisconsin Diagnostic

Fecha de actualizacion: 13 de julio de 2026

Resumen ejecutivo

Se desarrollo un flujo reproducible de clasificacion binaria que compara regresion logistica y random forest. El proceso incluye limpieza, versionamiento, analisis exploratorio, validacion cruzada estratificada de cinco pliegues, ajuste mediante GridSearchCV, evaluacion independiente y registro de resultados. La regresion logistica obtuvo el mejor F1-score de prueba (0.9861) y ROC-AUC (0.9960).

1. Descripcion del dataset

El conjunto Breast Cancer Wisconsin Diagnostic se distribuye mediante scikit-learn y contiene 569 observaciones. Cada fila representa mediciones calculadas a partir de imagenes digitalizadas de una aspiracion con aguja fina de una masa mamaria. La variable objetivo **diagnostico** usa 0 para maligno y 1 para benigno.

Elemento	Descripcion
Registros	569
Predictores	30 variables numericas
Objetivo	diagnostico
Clases	0 = maligno; 1 = benigno
Division	80% entrenamiento; 20% prueba
Semilla	42

Diccionario de datos. Las variables se organizan en diez caracteristicas geometricas o de textura: radius, texture, perimeter, area, smoothness, compactness, concavity, concave points, symmetry y fractal dimension. Cada caracteristica aparece en tres variantes: mean, error y worst, para un total de 30 predictores.

Supuestos. Los registros representan mediciones clinicas validas; los extremos no se eliminan automaticamente porque pueden corresponder a tumores reales. No existen variables categoricas predictoras, por lo que no se requiere codificacion one-hot.

2. Limpieza y estandarizacion


Criterio	Implementacion
Duplicados	Eliminacion mediante drop_duplicates().
Valores nulos	Conversion numerica e imputacion con la mediana de cada predictor.
Tipos de datos	Predictores numericos; objetivo convertido a entero y validado como binario.
Escalado	StandardScaler dentro del Pipeline de regresion logistica.
Categoricas	No aplica: todos los predictores son numericos.
Reglas	Conservar valores atipicos plausibles y evitar fuga de datos.

El escalado se ajusta dentro de cada fold de validacion cruzada. De este modo, la media y desviacion estandar del conjunto de validacion o prueba no participan en el ajuste y se evita data leakage.


3. Estrategia de versionamiento

El repositorio conserva el dataset original en **datos/datos_ini** y la version procesada en **datos/datos_limp**. Los cambios funcionales y decisiones se registran en CHANGELOG.md y README.md. El notebook genera un manifiesto JSON con version, fecha, dimensiones y huellas SHA-256 de los archivos original y limpio.


4. Visualizaciones: patrones y anomalías



La clase benigna es mayoritaria, pero el desbalance es moderado. Por ello se usa StratifiedKFold para conservar la proporción de clases en cada fold.



Los boxplots muestran observaciones extremas, especialmente en variables de área y perímetro. Se conservan porque pueden representar casos clínicos genuinos, no errores de captura.



Las variables de radio, perimetro y area presentan correlacion elevada. Esto evidencia redundancia parcial y justifica comparar un modelo lineal con un ensamble de arboles.

5. Modelos entrenados

Regresion logistica. Modelo lineal probabilistico e interpretable. Se combina con StandardScaler para que la regularizacion opere sobre variables comparables.

Random forest. Ensamble de arboles de decision capaz de capturar interacciones y relaciones no lineales. Es menos sensible a escalas diferentes, aunque se evaluo con el mismo conjunto de entrenamiento y prueba.

6. Configuracion de hiperparametros

Modelo	Cuadrícula evaluada	Mejor configuración
Regresion logistica	C: 0.1, 1.0; solver: liblinear; class_weight: None, balanced	C=0.1; solver=liblinear; class_weight=None
Random forest	n_estimators: 20, 50; max_depth: None, 10; min_samples_split: 2, 5; min_samples_leaf: 1, 2; class_weight=None, balanced	n_estimators=50; max_depth=None; min_samples_split=2; class_weight=balanced

El ajuste se realizo con GridSearchCV, F1 como criterio de refit y StratifiedKFold de cinco pliegues.

7. Metricas obtenidas

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	F1 CV	Desv. F1 CV
regresion logistica	0.9825	0.9861	0.9861	0.9861	0.9960	0.9861	0.0043
random forest	0.9474	0.9583	0.9583	0.9583	0.9939	0.9702	0.0142

8. Comparacion estadistica

La comparacion combina el rendimiento sobre el conjunto de prueba con la media y desviacion del F1 en validacion cruzada. La regresion logistica supera a random forest en F1 de prueba por 0.0278 puntos y tambien presenta mayor F1 medio de validacion. Su desviacion de F1 es menor (0.0043 frente a 0.0142), lo que indica mayor estabilidad entre folds.

Aunque ambos modelos obtienen ROC-AUC superior a 0.99, la regresion logistica ofrece el mejor equilibrio entre precision y recall. Por esta razon se selecciona como modelo final. La diferencia debe interpretarse dentro de este dataset y particion; no implica superioridad universal del algoritmo.

9. Trazabilidad y archivos generados

El repositorio final incluye comparacion_modelos.csv, mejor_modelo.json, resultados completos de GridSearchCV, matrices de confusion, modelos serializados, notebook final, scripts de preparacion y entrenamiento, README.md y CHANGELOG.md.

10. Conclusion

El proyecto cumple con limpieza reproducible, estandarizacion sin fuga de informacion, versionamiento, visualizaciones fundamentadas, comparacion de algoritmos, ajuste de hiperparametros y evaluacion estandarizada. La regresion logistica se recomienda como modelo final por su F1 de 0.9861, ROC-AUC de 0.9960, estabilidad y facilidad de interpretacion.